

Técnicas en las predicciones de la evolución de precios aplicados en el mercado de divisas (Forex)

David Melvin Requejo Santa Cruz¹ , Junior Cercado Vasquez¹ ,
Miguel Angel Valles Coral¹ , Cristian Wérner Garcia Estrella²

¹Universidad Peruana Unión, Perú

²Universidad Nacional de San Martín, Perú

{davidrequejo, juniorcercado, miguel.valles}@upeu.edu.pe, cgarcia@unsm.edu.pe

Resumen. A causa de su fuerte volatilidad del mercado de divisas, es complicado pronosticar la evolución del precio de cualquier par de divisas. Nuestro objetivo es realizar una revisión sistemática de la literatura sobre las técnicas para predecir la evolución de precios aplicados en Forex. Para ello realizamos búsqueda de artículos a partir de la combinación de operadores booleanos y revisión de artículos en bases de datos como Scopus y Web of Science. Se consideraron los artículos publicados entre los años 2018 y 2022, respectivamente, en idioma español e inglés. Existen dos técnicas comunes que permiten predecir la evolución de los precios en Forex, el primero es una técnica manual que combina tres factores, experiencia del trader, análisis técnico y fundamental, análisis técnico gira en torno a la identificación de un conjunto de patrones. El segundo es una técnica automatizada basado en modelos de Machine Learning como, CNN, RNN, LSTM, Q-LEARNING, ANN, DNN entre otros, estos utilizan los precios o imágenes de las divisas para su aprendizaje, siendo las redes neuronales convolucionales que logran resultados superiores al 70%, del mismo modo los modelos híbridos ofrecen resultados superiores al 60%.

Palabras clave. Forex, Machine Learning, finanzas, redes neuronales, bolsas de valores.

Abstract. Due to the high volatility of the foreign exchange market, it is difficult to forecast the price evolution of any currency pair. Our objective is to perform a systematic literature review on the techniques to predict the price evolution applied in Forex. To this end, we conducted a search for articles using a combination of Boolean operators and a review of articles in databases such as Scopus and Web of Science. Articles published between 2018 and 2022, respectively, in Spanish and English language were considered. There are two common techniques that allow predicting the evolution of prices in Forex, the first is a manual technique that combines three factors, trader experience, technical and fundamental analysis, technical analysis revolves around the identification of a set of patterns. The second is an automated technique based on Machine Learning models such as, CNN, RNN, LSTM, Q-LEARNING, ANN, DNN among others, these use the prices or images of currencies for learning, being convolutional neural networks that

achieve results above 70%, similarly hybrid models offer results above 60%.

Keywords. Forex, Machine Learning, finance, neural networks, stock exchanges.

1 Introducción

El mercado de divisas, conocido como *Forex*, es el mercado financiero de intercambio de monedas más grande del mundo [1] con una facturación diaria que se evalúa en más de 6 billones de dólares [2]. Este es un mercado descentralizado que opera las 24 horas del día, excepto los fines de semana[3]; su tiempo de negociación se divide en zona australiana, asiática, europea y norteamericana, cada una con sus horarios de apertura y cierre [4]. *Forex* es operado por bancos, instituciones financieras y comerciantes individuales o *traders* [5]. En él se negocian diferentes monedas (divisas) de distintos países [3] y es pieza fundamental de la economía mundial. Los inversores se benefician de la compra o venta de monedas, también conocido como par de divisas [6].

Realizar operaciones de compra y venta en *Forex* implica enfrentar altos riesgos como aprovechar oportunidades de grandes beneficios para los *traders*. De hecho como lo afirman [7], el riesgo y las oportunidades de estos negocios se deben a la concurrencia de factores económicos, políticos y psicológicos altamente correlacionados que interactúan de manera compleja.

En ese sentido, según [8] para que los *traders* tomen decisiones de compra y/o venta, constantemente buscan, analizan y utilizan herramientas que les ayuden a maximizar su rentabilidad y minimizar el riesgo; ya sea mediante análisis fundamental o análisis técnico. Así, el análisis fundamental basa en las noticias de *Forex* para predecir la tendencia del mercado como la tasa de inflación, la tasa de interés, el crecimiento económico, etc. [8]; y,

como apoyo del análisis técnico correcto es importante la identificación de patrones gráficos repetitivos del comportamiento del mercado.

Con mayor detalle, el análisis técnico gira en torno a la identificación de un conjunto de patrones gráficos predefinidos, y entre los más comunes encontramos banderas, banderines, hombro cabeza hombro, doble y triple piso [9]. Según [10], esto se puede utilizar para pronosticar las fluctuaciones de precios según las reglas de inferencia comúnmente aceptadas y adoptadas por los *traders*.

Al respecto, [9] sostienen que la utilización de patrones gráficos de la evolución de los precios del mercado es la forma más fácil de analizar su proyección; por su parte [10] mencionan que todavía tienen inconvenientes debido a las propiedades de distorsión del tiempo de los patrones de gráficos y la dependencia de una gran cantidad de patrones de gráficos predefinidos. Por lo tanto, urge la necesidad de buscar soluciones que ayuden a entender este comportamiento para proporcionar información que ayude a tomar mejores decisiones a los *traders*.

El reconocimiento de patrones requiere un análisis deliberado de la experiencia del trading en lugar de un análisis numérico puro, este reconocimiento requiere que los comerciantes hagan juicios visuales sobre las imágenes; para [11] existen algunos algoritmos que son adecuados para el reconocimiento de imágenes.

Según [12], utilizar métodos basados en el aprendizaje profundo para el modelado financiero está aumentando exponencialmente puesto que tiene mayor precisión y rendimiento en el campo de la predicción y el pronóstico financiero. Así, [13] han logrado que su modelo obtenga una precisión del 98,8% en la identificación de patrones en Forex.

Por su parte [14] utilizaron redes neuronales con tres capas ocultas de neuronas ReLU, a estos los entrenan como agentes RL bajo el algoritmo Q-learning, para lo cual utilizaron 8 años de datos del par de divisa EUR/USD de donde obtienen una ganancia total promedio de 16% anual del capital inicial.

En vista de lo anterior, nos planteamos como objetivo realizar una revisión sistemática de la literatura sobre las tendencias tecnológicas para predicciones de evolución de precios aplicados en el mercado de divisas Forex y conocer la efectividad de los mismos, teniendo en cuenta el análisis técnico sobre la tendencia de los precios en las divisas.

2 Materiales y métodos

Para lograr el objetivo planteado, aplicamos tres 03 fases metodológicas para la búsqueda y análisis de la literatura: Fase I. Elaboración de la pregunta de investigación; Fase II. Búsqueda de artículos científicos; y Fase III. Revisión, selección y análisis de estudios.

2.1 Fases de la búsqueda y análisis de la literatura

2.1.1 Elaboración de la pregunta de investigación

¿Qué técnicas se utiliza para la predicción de evolución de precios aplicados Forex?

¿Qué técnicas de machine learning ofrecen mejores resultados en la predicción Forex?

2.1.2. Búsqueda de artículos científicos

Realizamos búsqueda de artículos a partir de la combinación de operadores booleanos y revisión de artículos científicos en bases de datos de Scopus, Web of Science (WOS) y SciELO.

Para los criterios de inclusión se consideró los artículos publicados entre los años 2018 y 2022, respectivamente, en idioma español, inglés.

2.1.3 Revisión y selección de estudios

Obtuvimos un total de 60 artículos. Los documentos tomados para esta revisión son artículos de revistas indexadas, los cuales importamos a Mendeley Desktop, para luego leerlos, y subrayarlos aplicando la técnica de paráfrasis para un mejor entendimiento.

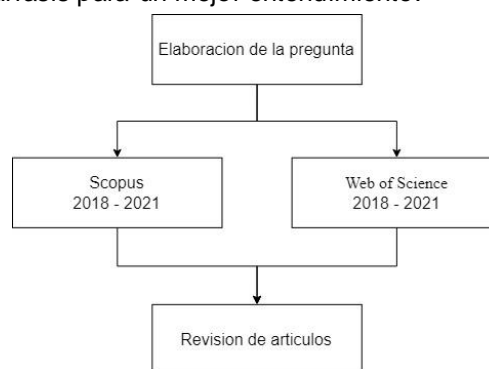


Fig. 1. Diagrama de selección de artículos

3 Resultados y discusión

3.1 Técnicas clásicas de análisis técnico en el mercado de divisas.

Forex el mercado de divisas más grande del mundo, permite que *Traders* comercialicen tomando decisiones de compra o venta, muchas de las decisiones se basan en el análisis de patrones gráficos o velas como por ejemplo el patrón grafico bandera, banderines, hombro cabeza hombro, doble y triple piso de manera similar el patrón de velas envolventes alcistas o bajistas, a partir de este análisis técnico y en función a su experiencia los *Traders* deciden realizar una operación y posteriormente se estima la ganancia/perdida; para ello se toma en consideración el patrón grafico detectado en conjunto del patrón de velas, realizado el análisis y ejecutada la operación se fija un punto de pérdida (*stop loss*) y punto de ganancia (*take profit*), con el fin de detener la pérdida o cerrar con ganancias respectivamente.

En relación a lo anterior [15] menciona que si el patrón de vela envolvente es alcista y acompañado por uno de los patrones gráficos doble piso, triple piso, se ejecuta una operación de compra al precio de oferta abierta de la siguiente vela, de manera similar si el patrón gráfico detectado es doble techo, triple techo o hombro cabeza hombro apoyados con patrones de velas envolvente bajistas entramos en una operación de venta al precio de oferta abierta de la siguiente vela, en consecuente se fija el punto de perdida por debajo del mínimo anterior o si se ha comprado o por encima del máximo anterior si se ha vendido, así como se muestra en la figura 2.



Fig. 2. Par de divisa GBP/USD a las 7:30 UTC-5 del 21/10/2022 en una temporalidad de 30 minutos.

Por otro lado [16] utilizaron el análisis técnico basado en el retroceso de Fibonacci en conjunto con ondas Eliot Wave. El análisis técnico Fibonacci son relaciones matemáticas, expresadas como proporciones, derivadas de las sucesiones de Fibonacci. Los principales índices de Fibonacci son 23,6%, 38,2%, 50% y 61,8%, estos índices se miden desde el inicio al final de un impulso donde el análisis Elliott wave nos ayuda a detectarlo. Elliott Wave está

formada por 5 ondas (1, 2, 3, 4, 5) según la tendencia alcista o bajista, al final de la tendencia hay un retroceso de 3 ondas (A, B, C). El retroceso de Elliott wave tiene proporción a los principales índices de Fibonacci. Las compra o ventas se toma al término del ciclo Elliott Wave en consideración de la tendencia alcista o bajista, así como lo muestra la figura 3 y 4.




Fig. 3. Gráfico teórico de las ondas de Elliott en conjunto con el retroceso de Fibonacci.



Fig. 4. Par de divisa GBP/USD a las 6:00 UTC-5 del 21/10/2022 en una temporalidad de 2 horas.

3.2. Las ventajas del uso de las herramientas tecnológicas en el mercado de divisas, y su influencia en el análisis técnico para una mejor toma de decisiones en el mercado Forex.

La predicción de *Forex* ha sido un interés clave para los *Traders* de todo el mundo. Se han aplicado numerosas tecnologías modernas además de modelos estadísticos a lo largo de los años [17].

Ya existen muchas herramientas para ayudar a las *Traders* a predecir las fluctuaciones de los precios, [18] menciona por ejemplo, las redes neuronales, el análisis de series temporales difusas, los algoritmos genéticos, los árboles de clasificación, los

modelos de regresión estadística y las máquinas de vectores de soporte. Sin embargo, estos modelos de aprendizaje automático son técnicas genéricas y se utilizan para realizar pronósticos. Se combinan inusualmente con la experiencia financiera.

3.2.1 Árboles de decisión

Según [19] desarrollaron dos sistemas de gestión de riesgos AIRMS-DT y AIRMS-ANN utilizando árboles de decisión y neuronales artificiales respectivamente. Para entrenar el sistema, cubriendo un período de siete años (2010-2016) con los 5 principales pares de divisas (GBP/USD, USD/JPY, EUR/USD, GBP/JPY y EUR/JPY). Donde cada punto de entrada (compra o venta) anteriores alimentan AIRMS para clasificar las señales producidas de la estrategia comercial en: rentables y no. AIRMS basado en DT primero logró alcanzar un retorno total de cada una de las monedas incrementándola a una tasa promedio del 50%, de manera similar AIRMS basado en ANN logró aumentar el rendimiento total de las cinco monedas en un promedio del 40%. Concluyendo que este sistema no promete rendimientos más del 80% pero si nos da una cartera rentable a través del tiempo.

3.2.2 Red Neuronal Convolutacional

Los investigadores [20] tomaron imágenes de gráficos de velas japonesa de los índices bursátiles de EEUU como entrada para entrenar el modelo *convolutional neural network* (CNN), este modelo CNN está formado por 6 capas ocultas, las cuatro primeras capas ocultas son capas convolucionales y las dos últimas capas ocultas son capas FC. En las capas FC, la ReLU se implementa sólo después de la quinta capa. Con el modelo implementado lograron que las carteras construidas a partir de los resultados, arrojen entre un 0,1% y un 1,0% de rentabilidad por transacción. Los resultados mostraron que algunos patrones gráficos indican los mismos movimientos de los precios de las acciones en los mercados bursátiles mundiales, llegando a la conclusión que el modelo implementado no solo funciona para el mercado donde se realizó el entrenamiento, sino que también funciona bien o incluso mejor en muchos otros.

Por otro lado [18] utilizaron el campo angular de Gramian (GAF), un nuevo método de codificación de series de tiempo, el cual permite representar datos de series de tiempo en un sistema de coordenadas y utilizar varias operaciones para convertir ángulos en matriz de simetría y las *convolutional neural network* (CNN), modelo que se utilizan

ampliamente en problemas de reconocimiento de patrones e imágenes, como primer paso utilizaron la codificar la serie temporal como diferentes tipos de imágenes con el método GAF, y en segunda instancia utilizaron las CNN con las imágenes GAF para el reconocimiento de patrones de velas japonesas.

Para el entrenamiento de los modelos utilizaron datos de precios de 1 minuto EUR/USD desde el 1 de enero de 2010 hasta el 1 de enero de 2018, incluidos 1000 datos de entrenamiento, 200 datos de validación y 350 datos de prueba, tras el entrenamiento de los modelos concluyeron que el modelo GAF-CNN puede identificar los ocho tipos de patrones de velas japonesas con una precisión promedio del 90,7 % [18].

Otra investigación realizada por [9] han propuesto un modelo que funciona conjuntamente con el patrón técnico de cruce de medias móviles. Para ello, han utilizado un modelo conjunto que se beneficia de dos tipos diferentes de técnicas de procesamiento inteligente, el procesamiento de imágenes que se aplica a las velas japonesas obtenidas del historial de precios y el análisis de series temporales que se aplica a las propiedades numéricas. Para el primer proceso, utilizaron la Red Neural Convolutacional (CNN) y para el último proceso, CNN con Memoria a Largo Corto Plazo (LSTM) para la predicción. Para el modelo propuesto se aplicaron datos del par EUR/USD. Las pruebas se realizaron para valores de dispersión de 0.5, 1, 1.5 y 2. Los investigadores lograron mostrar que el modelo híbrido logra resultados superiores en comparación con los patrones de análisis técnico del Índice de Fuerza Relativa (RSI) y Bandas de Bollinger (BB) individuales.

En cuanto a los investigadores [17] presentaron un nuevo modelo híbrido, Caos+CNN+PR, este está formado por la teoría del caos, la red neuronal convolutacional (CNN) y la regresión polinómica (PR) respectivamente, primero comprobaron si las series temporales financieras son confusas usando la Teoría del Caos, luego a las series temporales obtenidas se introdujeron en la CNN para obtener predicciones iniciales, posteriormente, con las series de errores obtenidas a partir de las predicciones de la CNN fueron ajustadas por PR para obtener predicciones de error, finalmente sumaron las predicciones de error y las predicciones iniciales de la CNN logrando obtener las predicciones finales. Para el entrenamiento utilizaron tipos de cambio de la Reserva Federal: rupias indias (INR) / USD, yen japonés (JPY) / USD, dólar de Singapur (SGD) / USD, índices bursátiles, Standard & Poor (S&P)500, Nifty 50 y Shanghai y precios

de productos básicos en dólares estadounidenses, el precio del petróleo crudo, el precio del oro y el precio de la soja, los datos se dividen en un conjunto de entrenamiento (80%) y un conjunto de prueba (20%) de observaciones, tras el entrenamiento y las pruebas los investigadores llegaron a la conclusión que el híbrido propuesto es superior a las medias móviles integradas autorregresivas (ARIMA), Prophet, Classification and Regression Tree (CART), Random Forest (RF), CNN.

Los autores [13] utilizaron el aprendizaje CNN profundo para predecir la dirección del cambio en los tipos de cambio EUR/USD, GBP/USD, JPY/USD. El entrenamiento se desarrolló a partir de 1565 precios de cierre, extraídos de los años 2010 y 2015, logrando obtener un detector que permite identificar los límites de los patrones de análisis técnico de diversos tamaños en los gráficos de precios. Como resultado de la investigación lograron concluir que el detector tiene con una precisión que gira en torno al 98,6% con una velocidad de respuesta de la NN Convolutiva de aproximadamente 0,65 segundos por 1000 muestras de datos.

3.2.3 Red neuronal recurrente

Los autores [21] utilizaron LSTM, para crear un modelo híbrido llamado "LSTM macroeconómico" (ME-LSTM) y "LSTM técnico" (TI-LSTM) que permite predecir el cambio direccional en el par de divisas EUR/USD, este modelo se compone de dos modelos LSTM independientes que tienen diferentes configuraciones de sus parámetros y que permite como entrada diversos grupos de datos, para el aprendizaje de los modelos, los datos se dividieron en conjuntos de entrenamiento y prueba, con proporciones de 80% y 20%, respectivamente. Como resultado obtuvieron que el modelo híbrido tiene un desempeño en términos de beneficio_precisión para las predicciones en promedio 73,61 %, los autores mencionan que han demostrado que su modelo sea eficaz en muchos problemas de pronóstico de series temporales, para hacer predicciones de dirección en Forex.

3.2.4 K vecinos más próximos

Los autores [3] utilizaron dos modelos del aprendizaje automático supervisado, con el objetivo de comparar la clasificación de patrones de precisión entre K-vecino más cercano (KNN) y el análisis discriminante lineal (LDA), además utilizaron el patrón de ondas Elliott Wave y los 3 niveles importantes de retroceso Fibonacci (38.2%, 50.0%, 61.8%) y el

error de estos tres niveles de pronóstico se analiza con tres herramientas de medida estadística, a saber, error absoluto medio (MAE), error cuadrático medio (RMSE) y para la correlación entre estos niveles utilizaron el coeficiente de correlación de Pearson (r). La divisa utilizada para este estudio fue GBP/USD, utilizando los precios de cotización de 4 meses, del 1 de marzo de 2016 hasta el 30 de junio de 2016 en horarios de s 2:00 p. m. y las 5:00 a. m. de lunes a sábado con intervalos de 5 minutos. Los resultados de precisión obtenidos de los modelos KNN Y LDA fueron 92.77% y 99.43% respectivamente, y con respecto al niveles de Fibonacci se logró para el nivel 38,2% MAE = 0.001884, RMSE = 0.000019 y $r = 0.992253$, para el nivel 50% MAE = 0.002493, RMSE = 0.000051 y $r = 0.990843$, para el nivel 61.8 % MAE = 0.003297, RMSE = 0.000091 y $r = 0.988842$. Llegaron a la conclusión que el modelo más óptimo es el LDA teniendo como precisión 99.43, además el nivel de retroceso de Fibonacci más eficiente es 38,2% dado que muestra el mejor pronóstico de MAE, RMSE y la correlación de Pearson.

Tabla 1. Técnicas utilizadas en la predicción de precios aplicados a Forex.

Técnicas	Método		Conjunto de datos	Periodo	Características	Resultado	Cita
CNN	CNN		EUR/USD, GBP/USD, JPY/USD	2010-2015	Datos de precios	98,6% precisión de predicción	[13]
	CNN, (Híbrido)	GAF	EUR/USD	2010 - 2018	Datos de precios	90,7% precisión.	[18]
	CNN, (Híbrido)	LSTM	EUR/USD	2020	Datos de precios. Imágenes de gráficos.	71% de precisión.	[9]
	CNN-LSTM (Híbrido)		Nifty 50	2011-2020	Datos de precios	34.2% de rendimiento anual	[22]
	DQN, (Híbrido)	CNN	Russell 3000	2001 - 2018	Imágenes de gráficos	Incremento de 10% a 100% de la cartera.	[20]
LSTM	LSTM		EUR/USD	2013 - 2018	Datos de precios	73.61% de precisión en promedio.	[21]
	LSTM		EUR/USD	2015 - 2018	Datos de precios	MSE = 10,96 %	[23]
	RNN, LSTM, (Híbrido)	GRU, MLP	EUR/USD, USD/JPY, USD/CHF, GBP/USD, USD/CAD y AUD/USD	2000 - 2019	Datos de precios	RNN = 27,18% GRU = 22,25% LSTM = 17,62% MLP = 20.62%	[24]
	CNN, (Híbrido)	LSTM	EUR/USD	2020	Datos de precios. Imágenes de gráficos.	71% de precisión.	[9]
	CNN-LSTM (Híbrido)		Nifty 50	2011-2020	Datos de precios	34.2% de rendimiento anual	[22]
Q-learning	Q-learning		EUR/USD	2010 - 2017	Datos de precios por ticks	Promedio anual de 16.3%	[14]
ANN	ANN, DT (Híbrido)		GBP/USD, USD/JPY, EUR/USD, GBP/JPY y EUR/JPY	2010 - 2016	Datos de precios	Incremento De 50% de la cartera.	[19]
DNN	DNN, (Híbrido)	ELM	Datos de transacciones de alta frecuencia de futuros CSI300	2017	Datos de precios	Accuracy DNN = 73,10% Accuracy ELM = 50,60% Accuracy RBF = 57,20%	[25]

Manual	Análisis técnico	Pares de divisa mayores y menores	2000 - 2018	Datos de precios	Incremento de 14% de la cartera.	[15]
	Onda de Elliott. Transformación rápida de Fourier. Redes neuronales artificiales.	EUR/USD, USD/JPY, CHF/JPY y EUR/CHF.	2015-2018	Datos de precios	50% a 72% precisión de predicción.	[26]
Otras técnicas	ELM, OSELM, RBPNN (Híbrido)	USD/INR, USD/EUR, SGD/INR, YEN/INR	2000 - 2016	Datos de precios	90% precisión de predicción.	[27]
	RLPNN-ISFL (Híbrido)	USD/AUD, USD/GBP, USD/INR	2014 - 2015	Datos de precios	60% precisión de predicción.	[28]
	Enfoque nítido.	Pares de divisa mayores y menores	2010 - 2018	Datos de precios	57% a 70% precisión de predicción.	[29]
	Enfoque difuso multicriterio.					

De acuerdo a la Tabla 1, se observa que las técnicas con mejores resultados para la predicción de precios de Forex son: CNN y LSTM, para el caso de la técnica CNN han sido considerados métodos híbridos a partir de la misma, tales como: CNN-GAF, CNN-LSTM y CNN- DQN, cabe destacar que el método CNN-LSTM es una mejora a partir de las técnicas más utilizadas, además, las divisas referentes con mayor frecuencia en el presente estudio son: Euros, Dólares, Libras Esterlinas, Nifty 50 (India) y Russell 3000 (EE.UU), por otra parte, el periodo de análisis de los conjuntos de datos están establecidos entre los años 2010 y 2020 usando como característica a datos de precios e imágenes, finalmente, los resultados de predicción de precios se encuentran entre el 98,6% y 34.2% .

Tabla 2. Técnicas de Machine Learning con resultados en la predicción de precios aplicados a Forex.

#	Técnica	Conjunto de datos	Periodo	Características	Resultado	Cita
1	CNN	EUR/USD, GBP/USD, JPY/USD	2010-2015	Datos de precios	98,6% precisión de predicción	[13]
2	CNN, GAF	EUR/USD	2010 - 2018	Datos de precios	90,7% precisión.	[18]
3	ELM, OSELM, RBPNN	USD/INR, USD/EUR, SGD/INR, YEN/INR	2000 - 2016	Datos de precios	90% precisión de predicción.	[27]
4	LSTM	EUR/USD	2015 - 2018	Datos de precios	MSE = 10,96 % Precisión = 89.04%	[23]
5	LSTM	EUR/USD	2013 - 2018	Datos de precios	73.61% de precisión en promedio.	[21]
6	CNN, LSTM	EUR/USD	2020	Datos de precios. Imágenes de gráficos.	71% de precisión.	[9]

7	Onda de Elliott. Transformación rápida de Fourier. Redes neuronales artificiales.	EUR/USD, USD/JPY, CHF/JPY y EUR/CHF.	2015-2018	Datos de precios	50% a 72% precisión de predicción.	[26]
8	RLPNN-ISFL	USD/AUD, USD/GBP, USD/INR	2014 - 2015	Datos de precios	60% precisión de predicción.	[28]
9	Enfoque nítido. Enfoque difuso multicriterio.	Pares de divisa mayores y menores	2010 - 2018	Datos de precios	57% a 70% precisión de predicción.	[29]
10	DNN, ELM	Datos de transacciones de alta frecuencia de futuros CSI300	2017	Datos de precios	Accuracy DNN = 73,10% Accuracy ELM = 50,60% Accuracy RBF = 57,20%	[25]
11	ANN, DT	GBP/USD, USD/JPY, EUR/USD, GBP/JPY y EUR/JPY	2010 - 2016	Datos de precios	Incremento De 50% de la cartera.	[19]
12	CNN-LSTM	Nifty 50	2011-2020	Datos de precios	34.2% de rendimiento anual	[22]
13	RNN, GRU, LSTM, MLP	EUR/USD, USD/JPY, USD/CHF, GBP/USD, USD/CAD y AUD/USD	2000 - 2019	Datos de precios	RNN = 27,18% GRU = 22,25% LSTM = 17,62% MLP = 20.62%	[24]
14	Q-learning	EUR/USD	2010 - 2017	Datos de precios por tics	Promedio anual de 16.3%	[14]
15	Análisis técnico	Pares de divisa mayores y menores	2000 - 2018	Datos de precios	Incremento de 14% de la cartera.	[15]
16	DQN, CNN	Russell 3000	2001 - 2018	Imágenes de gráficos	Incremento de 10% a 100% de la cartera.	[20]

De acuerdo a la Tabla 2, se observa que las técnicas de CNN y CNN-GAF (Híbrido) para par de divisas en Euros, Dólares, Libras Esterlinas, Yen Japonés obtuvieron una precisión de la predicción de 90.7% hasta 98.6% en el periodo de 2010 hasta el 2018, además, la técnica de ELM, OSELM y RBPNN (Híbrido) para par de divisas en Euros, Dólares, Libras Esterlinas, Yen Japonés y Rupias obtuvieron una precisión de la predicción del 90% en el periodo de 2000 hasta el 2016, por otra parte, la técnicas de LSTM y LSTM-CNN (Híbrido) para las divisas de Euros y Dólares obtuvieron un precisión de 73.61% hasta el 89.04% en datos de precios y el 71% en imágenes de gráficos en el periodo de 2013 hasta el 2020.

4 Conclusión

Las técnicas con mejores resultados para la predicción de precios de Forex son: CNN y LSTM, las cuales se aplican a través de técnicas híbridas para el mejoramiento de la predicción de los precios en Forex para par divisas en euros, dólares y libras esterlinas, obteniendo resultados de predicción de precios entre el 98,6% y 34.2%.

Las técnicas de Machine Learning con mejores resultados son las CNN, CNN-GAF (Híbrido), ELM, OSELM, RBPNN (Híbrido), LSTM y LSTM-CNN (Híbrido), los cuales fueron referenciados entre los años 2010 y 2020 estableciendo una predicción de precios en Forex entre el 98.6% y el 71%, cabe resaltar que para ambas técnicas estudiadas se consideraron a las divisas de euros, dólares, libras esterlinas y yen japonés como las más frecuentes.

Agradecimientos

Agradecemos a los docentes de la Universidad Peruana Unión por apoyo constante y los conocimientos brindados.

Referencias

- [1] M. Fisichella and F. Garolla, "Can Deep Learning Improve Technical Analysis of Forex Data to Predict Future Price Movements?," *IEEE Access*, vol. 9, pp. 153083–153101, 2021, doi: 10.1109/ACCESS.2021.3127570.
- [2] L. Ni, Y. Li, X. Wang, J. Zhang, J. Yu, and C. Qi, "Forecasting of Forex Time Series Data Based on Deep Learning," in *Procedia Computer Science*, 2019, vol. 147, pp. 647–652. doi: 10.1016/j.procs.2019.01.189.
- [3] A. Pornwattanavichai, S. Maneeroj, and S. Boonsiri, "BERTFOREX: Cascading Model for Forex Market Forecasting Using Fundamental and Technical Indicator Data Based on BERT," *IEEE Access*, vol. 10, pp. 23425–23437, 2022, doi: 10.1109/ACCESS.2022.3152152.
- [4] M. S. Islam, E. Hossain, A. Rahman, M. S. Hossain, and K. Andersson, "A Review on Recent Advancements in FOREX Currency Prediction," *Algorithms*, vol. 13, no. 8, p. 186, Jul. 2020, doi: 10.3390/a13080186.
- [5] L. Munkhdalai, T. Munkhdalai, K. H. Park, H. G. Lee,

- M. Li, and K. H. Ryu, "Mixture of Activation Functions with Extended Min-Max Normalization for Forex Market Prediction," *IEEE Access*, vol. 7, pp. 183680–183691, 2019, doi: 10.1109/ACCESS.2019.2959789.
- [6] S. Dash *et al.*, "A Novel Algorithmic Forex Trade and Trend Analysis Framework Based on Deep Predictive Coding Network Optimized with Reptile Search Algorithm," *Axioms*, vol. 11, no. 8, p. 396, Aug. 2022, doi: 10.3390/axioms11080396.
- [7] R. Jarusek, E. Volna, and M. Kotyrba, "FOREX rate prediction improved by Elliott waves patterns based on neural networks," *Neural Networks*, vol. 145, pp. 342–355, Jan. 2022, doi: 10.1016/j.neunet.2021.10.024.
- [8] W. Pongsena, P. Sitsayabut, N. Kerdprasop, and K. Kerdprasop, "Development of a Model for Predicting the Direction of Daily Price Changes in the Forex Market Using Long Short-Term Memory," *Int. J. Mach. Learn. Comput.*, vol. 11, no. 1, pp. 61–67, Jan. 2021, doi: 10.18178/ijmlc.2021.11.1.1015.
- [9] A. Hadizadeh Moghaddam and S. Momtazi, "Image processing meets time series analysis: Predicting Forex profitable technical pattern positions," *Appl. Soft Comput.*, vol. 108, p. 107460, Sep. 2021, doi: 10.1016/j.asoc.2021.107460.
- [10] Y. L. Yong, Y. Lee, and D. C. L. Ngo, "Adaptive detection of FOREX repetitive chart patterns," *Pattern Anal. Appl.*, vol. 23, no. 3, pp. 1277–1292, Aug. 2020, doi: 10.1007/s10044-019-00862-8.
- [11] Y. C. Tsai, J. H. Chen, and J. J. Wang, "Predict Forex Trend via Convolutional Neural Networks," *J. Intell. Syst.*, vol. 29, no. 1, pp. 941–958, Sep. 2020, doi: 10.1515/jisys-2018-0074.
- [12] Z. Hu, Y. Zhao, and M. Khushi, "A survey of forex and stock price prediction using deep learning," *Applied System Innovation*, vol. 4, no. 1, pp. 1–30, Feb. 02, 2021, doi: 10.3390/ASI4010009.
- [13] L. Jing, Z. Li, X. Peng, J. Li, and S. Jiang, "A Relative Equilibrium Decision Approach for Concept Design Through Fuzzy Cooperative Game Theory," *J. Comput. Inf. Sci. Eng.*, vol. 19, no. 4, Dec. 2019, doi: 10.1115/1.4042837.
- [14] J. Carapuço, R. Neves, and N. Horta, "Reinforcement learning applied to Forex trading," *Appl. Soft Comput. J.*, vol. 73, pp. 783–794, Dec. 2018, doi: 10.1016/j.asoc.2018.09.017.
- [15] A. S. Alanazi, "The bullish and the bearish engulfing patterns: beating the forex market or being beaten?," *Eur. J. Financ.*, vol. 26, no. 15, pp. 1484–1505, Oct. 2020, doi: 10.1080/1351847X.2020.1748679.
- [16] M. F. Ramli, A. K. Junoh, M. A. Wahab, and W. Z. A. W. Muhamad, "Fibonacci retracement pattern recognition for forecasting foreign exchange market," *Int. J. Bus. Intell. Data Min.*, vol. 17, no. 2, pp. 159–178, 2020, doi: 10.1504/IJBIDM.2020.108775.
- [17] D. M. Durairaj and B. H. K. Mohan, "A convolutional neural network based approach to financial time series prediction," *Neural Comput. Appl.*, vol. 34, no. 16, pp. 13319–13337, Aug. 2022, doi: 10.1007/s00521-022-07143-2.
- [18] J. H. Chen and Y. C. Tsai, "Encoding candlesticks as images for pattern classification using convolutional

- neural networks," *Financ. Innov.*, vol. 6, no. 1, p. 26, Dec. 2020, doi: 10.1186/s40854-020-00187-0.
- [19] S. K. Chandrinios, G. Sakkas, and N. D. Lagaros, "AIRMS: A risk management tool using machine learning," *Expert Syst. Appl.*, vol. 105, pp. 34–48, Sep. 2018, doi: 10.1016/j.eswa.2018.03.044.
- [20] J. Lee, R. Kim, Y. Koh, and J. Kang, "Global Stock Market Prediction Based on Stock Chart Images Using Deep Q-Network," *IEEE Access*, vol. 7, pp. 167260–167277, 2019, doi: 10.1109/ACCESS.2019.2953542.
- [21] D. C. Yildirim, I. H. Toroslu, and U. Fiore, "Forecasting directional movement of Forex data using LSTM with technical and macroeconomic indicators," *Financ. Innov.*, vol. 7, no. 1, p. 1, Dec. 2021, doi: 10.1186/s40854-020-00220-2.
- [22] A. Shah, M. Gor, M. Sagar, and M. Shah, "A stock market trading framework based on deep learning architectures," *Multimed. Tools Appl.*, vol. 81, no. 10, pp. 14153–14171, Apr. 2022, doi: 10.1007/s11042-022-12328-x.
- [23] S. Ahmed, S. U. Hassan, N. R. Aljohani, and R. Nawaz, "FLF-LSTM: A novel prediction system using Forex Loss Function," *Appl. Soft Comput. J.*, vol. 97, p. 106780, Dec. 2020, doi: 10.1016/j.asoc.2020.106780.
- [24] L. Munkhdalai, T. Munkhdalai, K. H. Park, H. G. Lee, M. Li, and K. H. Ryu, "Mixture of Activation Functions With Extended Min-Max Normalization for Forex Market Prediction," *IEEE Access*, vol. 7, pp. 183680–183691, 2019, doi: 10.1109/ACCESS.2019.2959789.
- [25] L. Chen, Z. Qiao, M. Wang, C. Wang, R. Du, and H. E. Stanley, "Which Artificial Intelligence Algorithm Better Predicts the Chinese Stock Market?," *IEEE Access*, vol. 6, pp. 48625–48633, 2018, doi: 10.1109/ACCESS.2018.2859809.
- [26] R. Jarusek, E. Volna, and M. Kotyrba, "FOREX rate prediction improved by Elliott waves patterns based on neural networks," *Neural Networks*, vol. 145, pp. 342–355, Jan. 2022, doi: 10.1016/j.neunet.2021.10.024.
- [27] S. R. Das, Kuhoo, D. Mishra, and M. Rout, "An optimized feature reduction based currency forecasting model exploring the online sequential extreme learning machine and krill herd strategies," *Phys. A Stat. Mech. its Appl.*, vol. 513, pp. 339–370, Jan. 2019, doi: 10.1016/j.physa.2018.09.021.
- [28] R. Dash, "Performance analysis of an evolutionary recurrent Legendre Polynomial Neural Network in application to FOREX prediction," *J. King Saud Univ. - Comput. Inf. Sci.*, vol. 32, no. 9, pp. 1000–1011, Nov. 2020, doi: 10.1016/j.jksuci.2017.12.010.
- [29] P. Juszczuk and L. Kruś, "Soft multicriteria computing supporting decisions on the Forex market," *Appl. Soft Comput. J.*, vol. 96, p. 106654, Nov. 2020, doi: 10.1016/j.asoc.2020.106654.

